

Tercer examen parcial

Sistemas Inteligentes II

Jorge Alberto Jaramillo Garzón
Universidad de Caldas

El repositorio de aprendizaje de máquina de la Universidad de California en Irvine (*UCI machine learning repository*) almacena más de 500 datasets que pueden ser usados en tareas de aprendizaje de máquina (<https://archive.ics.uci.edu/ml/index.php>).

- 1) **(1.0)** Cada estudiante debe ingresar a la página de la UCI y escoger una base de datos con características categóricas, numéricas o mixtas para un problema de clasificación. A continuación, entrenará un modelo de árbol de decisión usando CART. El estudiante deberá:

- Analizar la estructura del árbol obtenido.
- Extraer e interpretar reglas explícitas de clasificación.
- Identificar cuáles reglas son más relevantes considerando aspectos como pureza, cobertura, profundidad y facilidad de interpretación.
- Evaluar el modelo usando validación cruzada.
- Comparar el desempeño del árbol antes y después de realizar poda (*pruning*) o ajustes de hiperparámetros.

Finalmente, deberá concluir sobre la interpretabilidad, capacidad de generalización y posibles limitaciones del modelo obtenido.

- 2) **(1.0)** Cada estudiante debe ingresar a la página de la UCI y escoger una base de datos adecuada para aprendizaje no supervisado (*clustering*).

Posteriormente aplicará clustering jerárquico usando diferentes criterios de enlazamiento (*single, complete, average y ward*). Para cada caso:

- Construya e interprete el dendrograma.
- Analice diferentes puntos de corte.
- Evalúe la calidad de los agrupamientos utilizando al menos dos métricas internas de clustering (por ejemplo: coeficiente de silueta, índice Davies-Bouldin, Calinski-Harabasz u otras).
- Compare cómo cambia la estructura de los clusters según el criterio de enlazamiento utilizado.

Finalmente, concluya cuál criterio de enlazamiento resulta más apropiado para la base de datos seleccionada y por qué.

- 3) **(1.0)** Cada estudiante debe ingresar a la página de la UCI y escoger una base de datos para regresión.

A continuación, entrenará y comparará los siguientes métodos:

- Regresión K-NN.
- Regresión ϵ -SVR.
- Redes neuronales artificiales para regresión.

El estudiante deberá:

- Ajustar los hiperparámetros relevantes de cada método.
- Evaluar el desempeño usando métricas apropiadas para regresión (MAE, MSE, RMSE, R^2 , etc.).
- Analizar posibles problemas de sobreajuste o subajuste.
- Comparar la capacidad de generalización y complejidad de los modelos.

Finalmente, deberá concluir cuáles métodos resultan más adecuados para la base de datos seleccionada y justificar sus conclusiones.

- 4) **(2.0)** Sustentación en horario de clase.

Entregable: Un notebook de Jupyter con código, salidas y comentarios personales. Puede emplear las librerías que considere pertinentes para la implementación de los modelos de aprendizaje de máquina.